编译原理

第三章 词法分析

方徽星
扬州大学 信息工程学院(505)
fanghuixing@yzu.edu.cn

2018年春季学期

词法分析器与语法分析器的关系

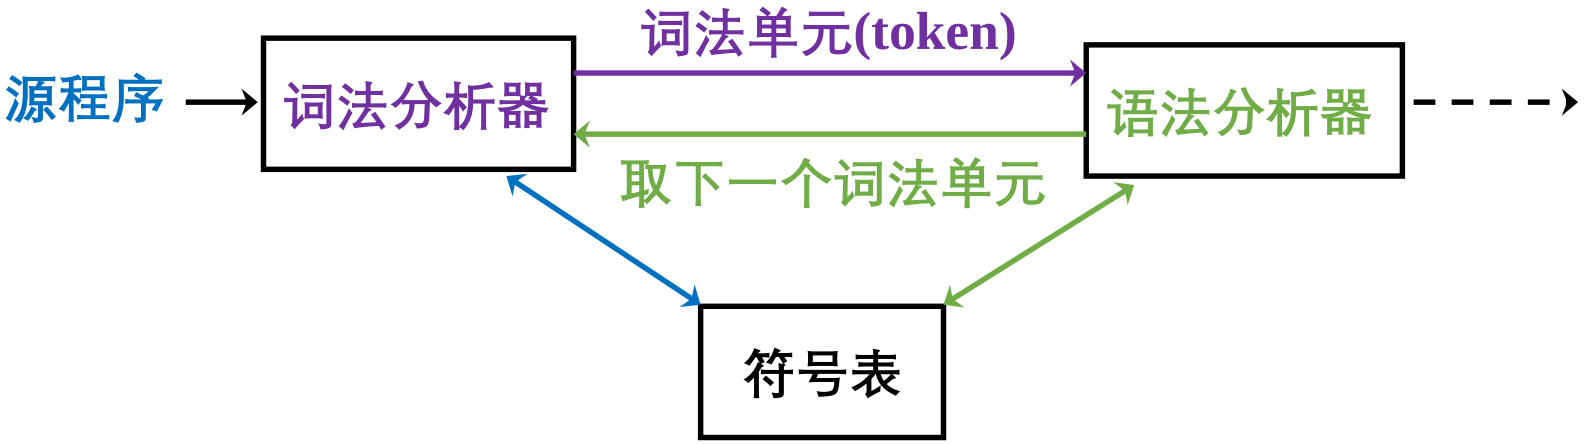

本章主要内容

一. 正规文法与有限自动机

- 正规文法、正规式、正规集
- 确定的有限自动机（DFA）
- 非确定的有限自动机（NFA）
- NFA的确定化
- DFA的简化
- 正规式与有限自动机之间的关系
- 正规文法与有限自动机之间的关系

二. 词法分析程序的设计

- 预处理与超前搜索
- 扫描器的输出格式
- 扫描器的设计

词法分析基本术语

- 词法单元
  - 词法单元名：抽象符号用于区别不同种类的词法单元，用于当作语法分析器的输入符号
  - 属性值（可选）：指针或常量值（由具体实现决定）
- 例：position = initial + rate * 60的词法单元名和属性值：

  ⟨id，指向符号表中position条目的指针⟩
  ⟨assign _ op⟩
  ⟨id，指向符号表中initial条目的指针⟩
  ⟨add_op⟩
  ⟨id，指向符号表中rate条目的指针⟩
  ⟨mul_ op⟩
  ⟨number，整数值60⟩

词法分析基本术语

- 模式：描述一个词法单元的词素可能具有的形式
- 词素：源代码中的实际字符序列，可与某词法单元模式相匹配，可被词法分析器识别为一个词法单元实例
- 例：词素示例

词素	词法单元名
if, else	Keyword
<=, !=	CompOp
index, score	ID
3.14159	FloatNumber

第一节 正规文法与有限自动机

1.1 正规文法、正规式、正规集

- 由正规文法产生的**语言**称为**正规集**,可以使用**正规式**来形式地表示正规集，设非空有限字母表$A = \{a_i \mid i = 1,2,\dots,n\}$,则
  - 空串符号**ε是正规式**，$L(\varepsilon) = \{\varepsilon\}$
  - 空集符号∅是正规式，$L(\varepsilon) = \{\}$
  - $a \in A$是正规式，$L(a) = \{a\}$
  - 如果α,β是正规式，则下面都是正规式：
    - $\alpha \mid \beta$，　$L(\alpha \mid \beta) = L(\alpha) \cup L(\beta)$　（或）
    - $\alpha \cdot \beta$，　$L(\alpha \cdot \beta) = L(\alpha)L(\beta)$　（连接）
    - α^*和β^*，$L(\alpha^*) = (L(\alpha))^*$　（闭包）
- 正规式扩展：α^+，$L(\alpha^+) = (L(\alpha))^+$；$\alpha?$，$L(\alpha?) = L(\alpha) \cup \{\varepsilon\}$；$[a_1 a_2 \cdots a_m] = a_1 \mid a_2 \mid \cdots \mid a_m$，[a−z]= a|b|⋯|z

1.1 正规文法、正规式、正规集

- 正规式代数定律：如果α，β，γ是正规式，则下述等式成立

定律	描述
$\alpha \mid \beta = \beta \mid \alpha$	交换律
$\alpha \mid (\beta \mid \gamma) = (\alpha \mid \beta) \mid \gamma$ $\alpha(\beta\gamma) = (\alpha\beta)\gamma$	结合律
$\alpha(\beta \mid \gamma) = \alpha\beta \mid \alpha\gamma$ $(\alpha \mid \beta)\gamma = \alpha\gamma \mid \beta\gamma$	分配律
$\varepsilon\alpha = \alpha\varepsilon = \alpha$	ε是连接的单位元
$(\alpha^*)^* = \alpha^*$	*具有幂等性
$\alpha^* = \alpha^+ \mid \varepsilon$	闭包中一定包含ε

1.1 正规文法、正规式、正规集

- 定理1： 设α，β，γ是字母表A上的正规式，则
  - $\alpha = \beta \mid \alpha\gamma$ 当且仅当 $\alpha = \beta\gamma^*$
  - $\alpha = \beta \mid \gamma\alpha$ 当且仅当 $\alpha = \gamma^*\beta$

- 由正规文法求解对应语言的正规式：
  - 首先由各个产生式写出对应的正规方程式，获得联立方程组
  - 这些方程组中的变元是非终结符，求解方程组得到一个关于开始符号的解

1.1 正规文法、正规式、正规集

- **例：** 已知正规文法的产生式如下：

  $S \to aS \mid aB,$　　$B \to bB \mid bA,$　　$A \to cA \mid c$

  求出它所定义的正规式

解：由产生式写出联立方程组：

$S = aS \mid aB$　　(1)

$B = bB \mid bA$　　(2)

$A = cA \mid c$　　(3)

由定理1，(1)的解为$S = a^*aB = a^+B$；

同理(2)的解为$B = b^*bA = b^+A$；

由(3)可得$A = c^*c = c^+$；

最后解得正规式$S = a^+b^+c^+$

1.2 确定的有限自动机

- 确定的有限自动机 (DFA: Deterministic Finite Automata)M=(S, Σ, f, s_0, Z)，其中：
  - S：有限状态集，S的每一个元素s称为状态
  - Σ：有穷字母表，Σ的每一个元素σ称为输入字符
  - f：$S \times \Sigma \to S$，转换函数，对于状态$s \in S$和输入符号$\sigma \in \Sigma$最多只有一条标号为σ的边离开状态s
  - $s_0 \in S$是初始状态
  - $Z \subseteq S$是终止状态集，Z为空集时，该DFA不接受任何东西

1.2 确定的有限自动机

- 例：DFA $\mathrm{M} = (\{0,1,2,3\}, \{\mathrm{a}, \mathrm{b}\}, f, 0, \{3\})$,其中 $S = \{0,1,2,3\}, \Sigma = \{\mathrm{a}, \mathrm{b}\}, s_0 = 0, Z = \{3\}$

  转换图如下所示：

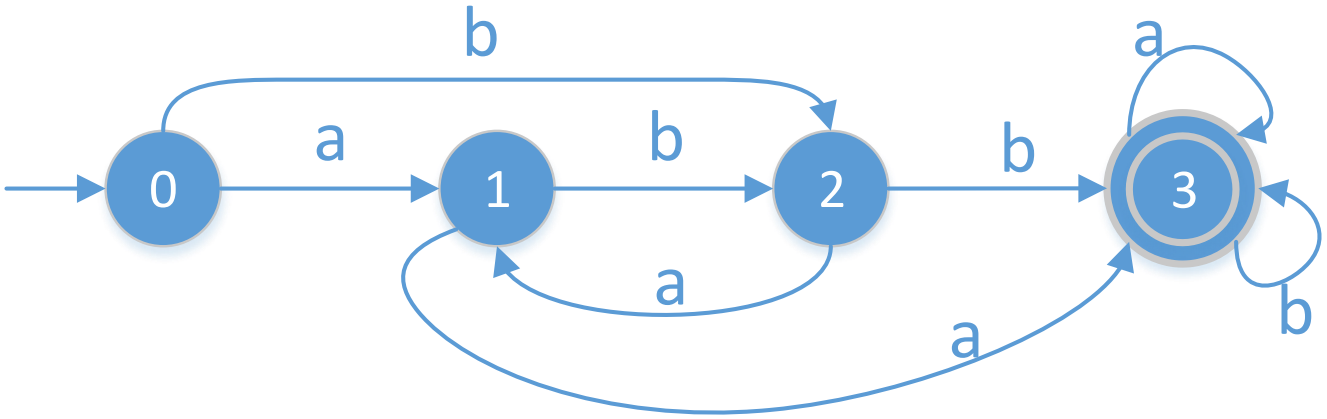

此例中转换函数f是如何定义的？

1.2 确定的有限自动机

- **状态转换图**用于表示词法分析器被语法分析器调用时，词法分析器为返回下一个词法单元所做的动作
  - 开始识别词法单元时，控制**进入开始状态**
  - 如果**离开状态**的某条边上的**标记与当前输入字符匹配**，则**进入目标状态**，否则识别过程失败
  - 由**双圈**表示的状态规定为**接受状态**，控制进入该类状态则表示**成功识别**了一个词法单元
  - 接受状态**可以有动作**，到达接受状态时执行该动作
  - 符号*：表示**需要回退**一个字符

1.2 确定的有限自动机

状态转换图示例

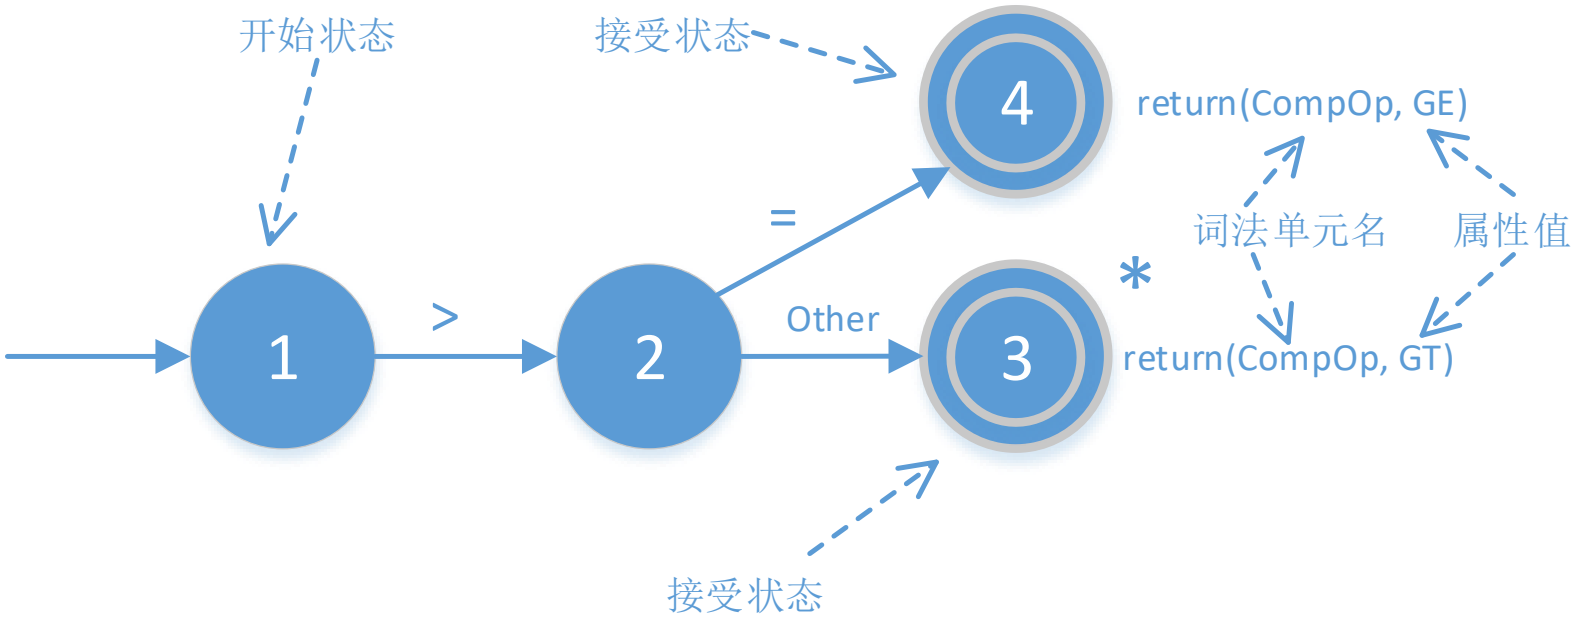

1.2 确定的有限自动机

- DFA接受输入串x，当且仅当转换图中存在从开始状态到某个终止状态的路径，使得该路径上各边上的标记组成x

DFA模拟算法

输入：一个以文件文件结束符EOF结尾的字符串x. DFA M的开始状态为s_0，终止状态集为Z，转换函数为f

输出：如果M接受x，则回答“yes”，否则回答“no”

```
s = s0;
c = nextChar();
While(c ≠ EOF){
        s = f(s, c);
        c = nextChar();
}

If (s ∈ Z)
        return “yes”;
Else
        return “no”;
```

1.3 非确定的有限自动机

- 非确定的有限自动机 (NFA: Nondeterministic Finite Automata)M=(S, Σ, f, s_0, Z)，其中：
  - S：有限状态集，S的每一个元素s称为状态
  - Σ：有穷字母表，Σ的每一个元素σ称为输入字符
  - f：$S \times \Sigma \cup \{\varepsilon\} \to 2^S$，转换函数，对于每个状态$s \in S$和每个输入符号$\sigma \in \Sigma$可能有多条标号为$\sigma$的边离开状态$s$
  - $s_0 \in S$是初始状态
  - $Z \subseteq S$是终止状态集，Z可为空集
- 确定与非确定的有限自动机能识别的语言的集合是相同的，且是能够用正规式描述的语言集合

1.3 非确定的有限自动机

- 例：NFA $M = (\{0,1,2,3\}, \{a, b\}, f, 0, \{3\})$,其中
  $S = \{0,1,2,3\}, \Sigma = \{a, b\}, s_0 = 0, Z = \{3\}$

  转换图如下所示：

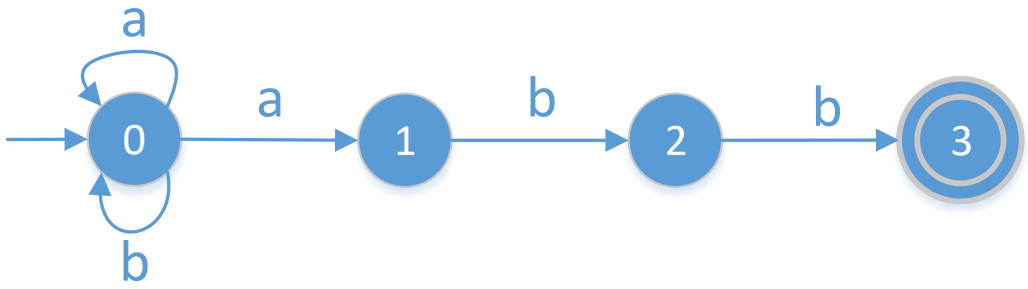

此例中转换函数f是如何定义的？

1.4 NFA的确定化

- 将NFA转换为DFA
- 子集构造算法(Subset Construction)：
  - 输入：一个NFA $N = (S_N, \Sigma_N, f_N, s_0^N, Z_N)$
  - 输出：一个DFA $D = (S_D, \Sigma_D, f_D, s_0^D, Z_D)$
  - 基本方法：构造D的状态和转换函数，D的每个状态对应N的一个状态集合，N中每个状态集合的转换对应D中的一个状态转换

1.4 NFA的确定化

子集构造算法主体：

一开始，ε-closure(s_0^N)是S_D中的唯一状态，且未加标记；
While (在S_D中有一个未标记的状态T) {
    给T加上标记；
    For (每个输入符号a) {
        U = ε-closure(move(T, a));
        If (U不在S_D中)
            Then 将U加入到S_D中，且不加标记；
        f_D(T, a) = U;
    }
}

操作	描述
ε-closure(s)	能够从NFA的状态s出发只通过ε转换到达的NFA状态集合
ε-closure(T)	能够从T中某个NFA的状态s出发只通过ε转换到达的NFA状态集合
move(T, a)	能够从T中某个NFA的状态s出发只通过a转换到达的NFA状态集合

1.4 NFA的确定化

- 例：下图给出了一个接受语言(a|b)*abb的NFA

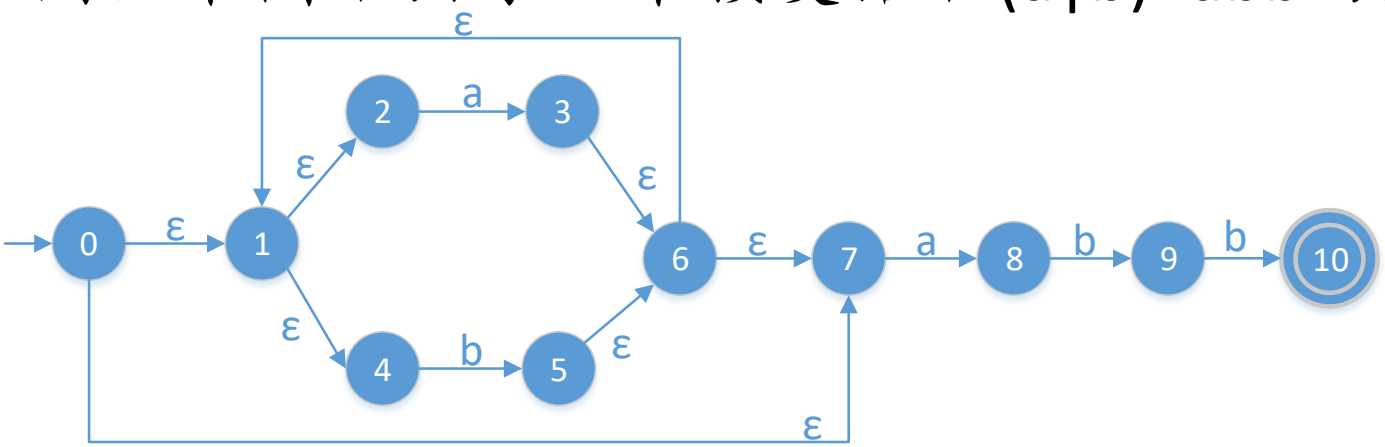

构造DFA：DFA的开始状态A为ε-closure(0)={0，1，2，4，7}

NFA状态集	DFA状态	符号a	符号b
{0,1,2,4,7}	A	move(A,a)={3,8} B=ε-closure({3,8}) ={1,2,3,4,6,7,8}	move(A,b)={5} C=ε-closure({5}) ={1,2,4,5,6,7}
{1,2,3,4,6,7,8}	B	?	?

1.5 DFA的简化

- 任何一个正则语言都有一个唯一的状态数目最少的DFA
- 从任意一个接受相同语言的DFA出发，通过分组合并等价状态，总可以构建得到该状态数最少的DFA
- 如果分别从状态s和t出发，沿着串x的路径到达的两个状态中只有一个是接受状态，则串x区分状态s和t
- 如果存在某个能够区分状态s和t的串，则s和t是可区分的

1.5 DFA的简化

- 最小化DFA状态数量算法

输入： DFA $D = (S, \Sigma, f, s_0, Z)$
输出： 最小化DFA D'

1. 首先构造包含两个组Z和$S \setminus Z$的初始分划P，分别是D的接受状态组和非接受状态组；

2. 构造新分划Pn；

3. 若Pn=P，令Pf=P跳到步骤4；否则，用Pn替换P并重复步骤2；

4. 在分划Pf的每个组中选取一个代表，则所有代表构成D'的状态：
   - D'的开始状态是D的开始状态所在组的代表，D'的接受状态是那些包含了D的接受状态所在组的代表；
   - 令s为某组代表，且$s \xrightarrow{a} t$，若r为t组的代表，则D'中有$s \xrightarrow{a} r$

1.5 DFA的简化

- 最小化DFA状态数量算法

令Pn = P;

For （P中的每个组G）{

　　将G划分为更小的组，使得两个状态s和t在同一个组中当且仅当对于所有的输入符号a，状态s和t在a上转换到P中的同一组里；

　　在Pn中将G替换为对G进行划分得到的那些小组；

}

构造新分划Pn

1.5 DFA的简化

- 例：将下图所示DFA最小化

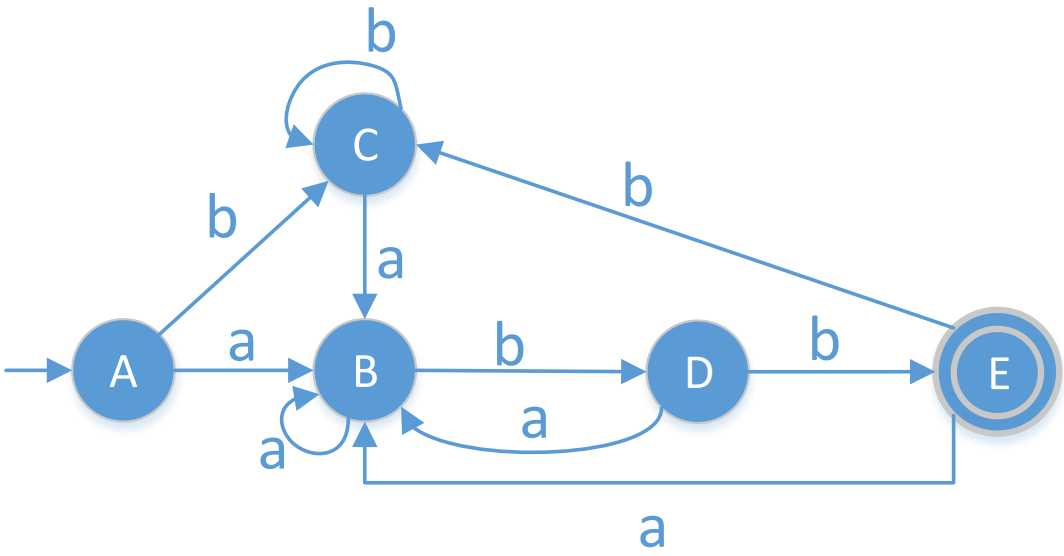

第一次分划：非接受和接受
第二次分划：D在b上不同于其他
第三次分划：B在b上不同于其他

分划树

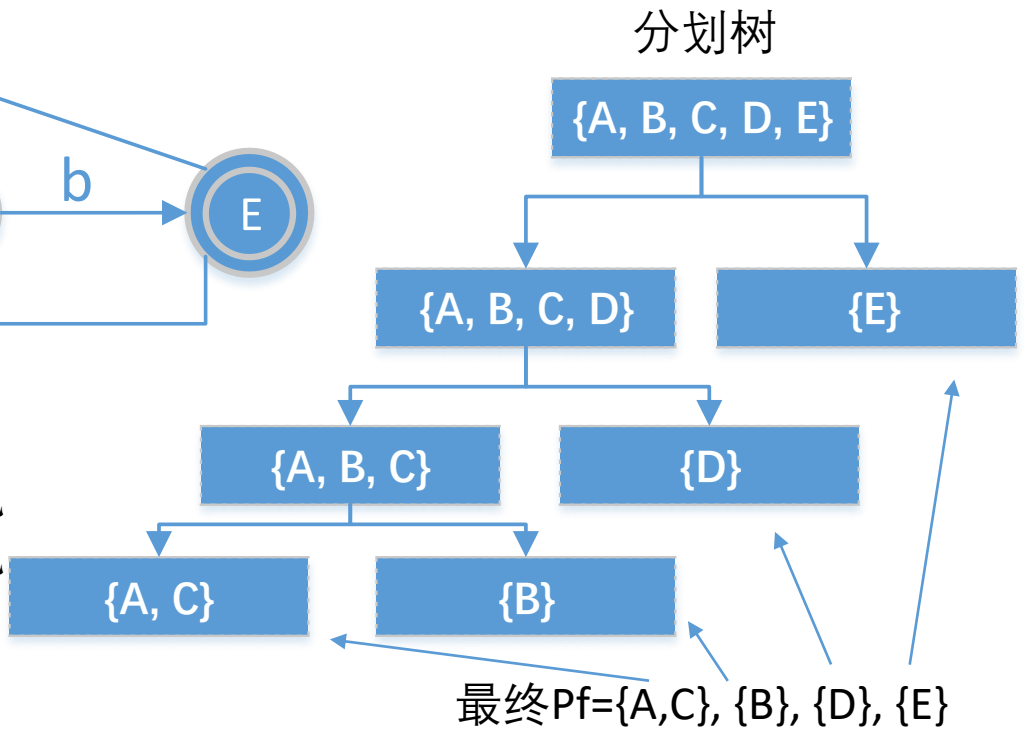

最终Pf={A,C}, {B}, {D}, {E}

1.6 正规式与有限自动机之间的关系

- 定理2： 字母表Σ上的NFA M所能识别的语言L(M)可以用Σ上的正规式表示
- 定理3：对于Σ上的任何正规式α，存在一个DFA M使得L(M)=L(α)
- 例：将下图所示的有限自动机使用正规式表示

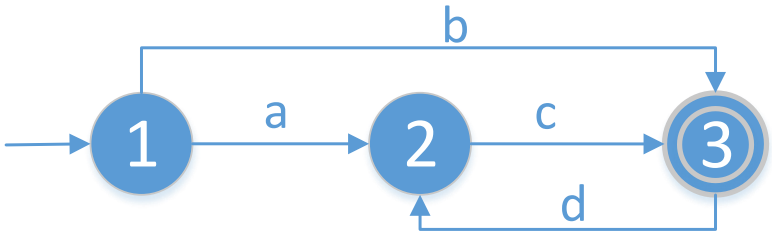

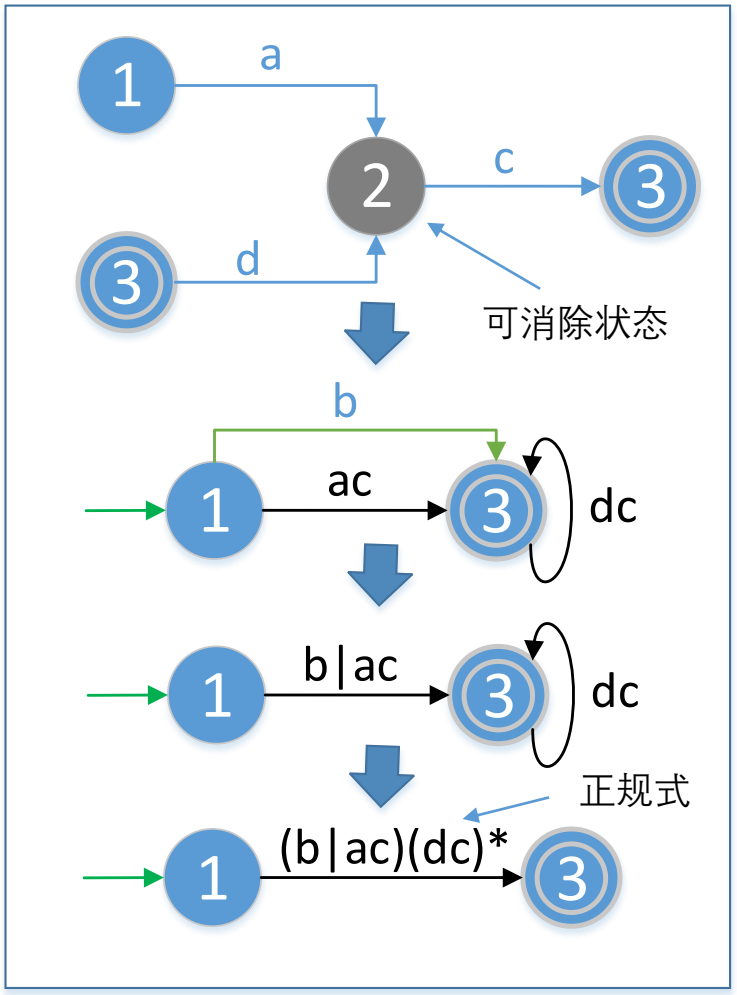

1.6 正规式与有限自动机之间的关系

- 由正规式构造NFA的McMaughton-Yamada-Thompson
  算法：沿着正规式的语法分析树自底向上递归地处理，对于每个子表达式，构造一个只有一个接受状态地NFA
  - **输入：**字母表Σ上的一个正规式γ
  - **输出：**一个接受$L(\gamma)$的NFA N
  - **方法：**首先对γ进行语法分析，分解出组成它的子表达式，然后使用构造规则

构造规则
- 基本规则：处理不包含运算符的子表达式
- 归纳规则：根据一个给定表达式的直接子表达式的NFA构造出这个表达式的NFA

1.6 正规式与有限自动机之间的关系

McMaughton-Yamada-Thompson算法

- 基本规则
  - 对于表达式ε，构造下面的NFA

（其中状态i，f都是新状态）

  - 对于字母表中的每个符号a，构造下面的NFA

（其中状态i，f都是新状态）

1.6 正规式与有限自动机之间的关系

McMaughton-Yamada-Thompson算法

- 归纳规则：假设正规式s和t的NFA分别是N(s)和N(t)，则
  - 如果$\gamma = s \mid t$，则γ的NFA，可以按照下图方式构造

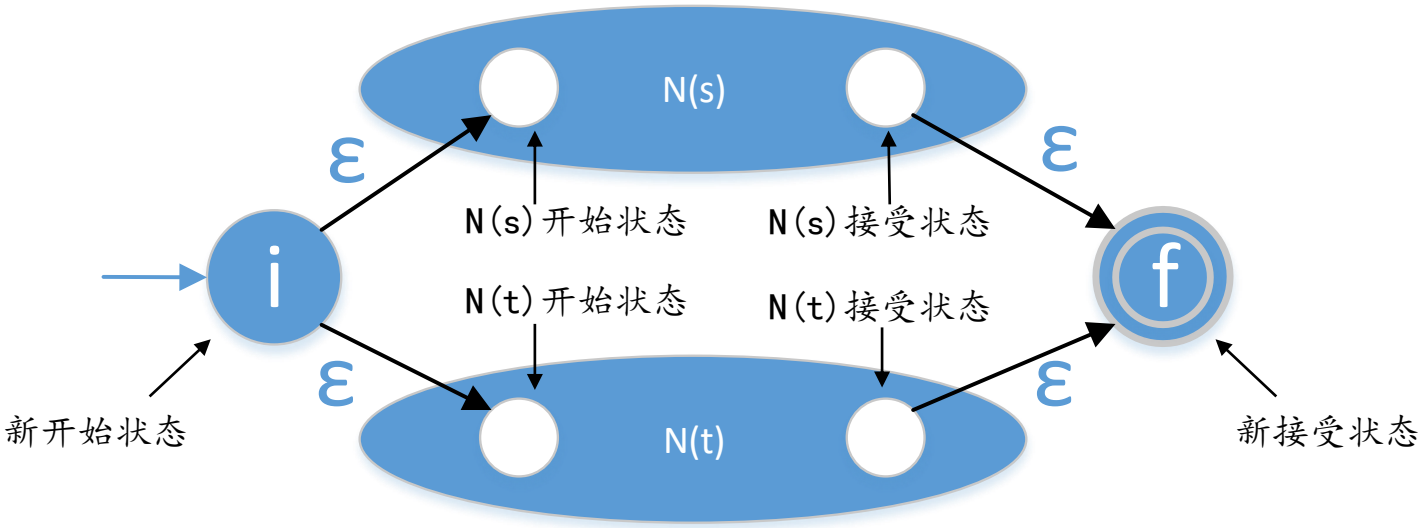

1.6 正规式与有限自动机之间的关系

McMaughton-Yamada-Thompson算法

- 归纳规则：假设正规式s和t的NFA分别是N(s)和N(t)，则
  - 如果γ = st，则γ的NFA，可以按照下图方式构造

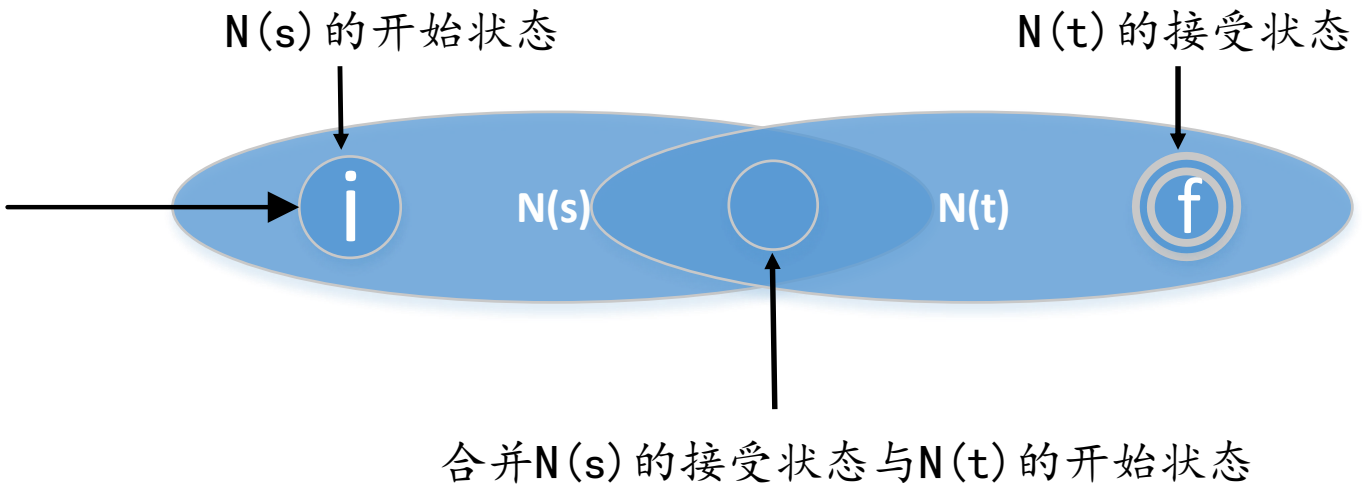

1.6 正规式与有限自动机之间的关系

McMaughton-Yamada-Thompson算法

- 归纳规则：假设正规式s和t的NFA分别是N(s)和N(t)，则
  - 如果γ = s*，则γ的NFA，可以按照下图方式构造

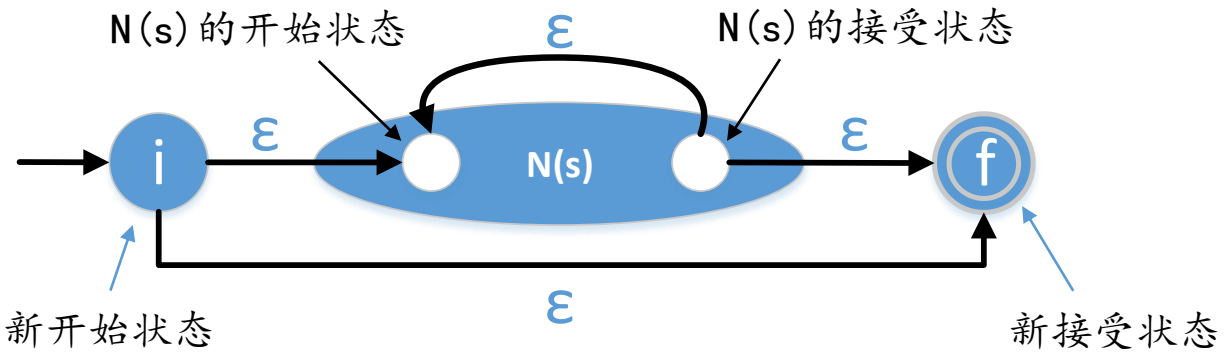

  - 如果γ = (s)，则L(γ)=L(s)，直接把N(s)当作N(γ)

1.6 正规式与有限自动机之间的关系

- 例：使用McMaughton-Yamada-Thompson算法为正规式r=(a | b)*abb构造一个NFA

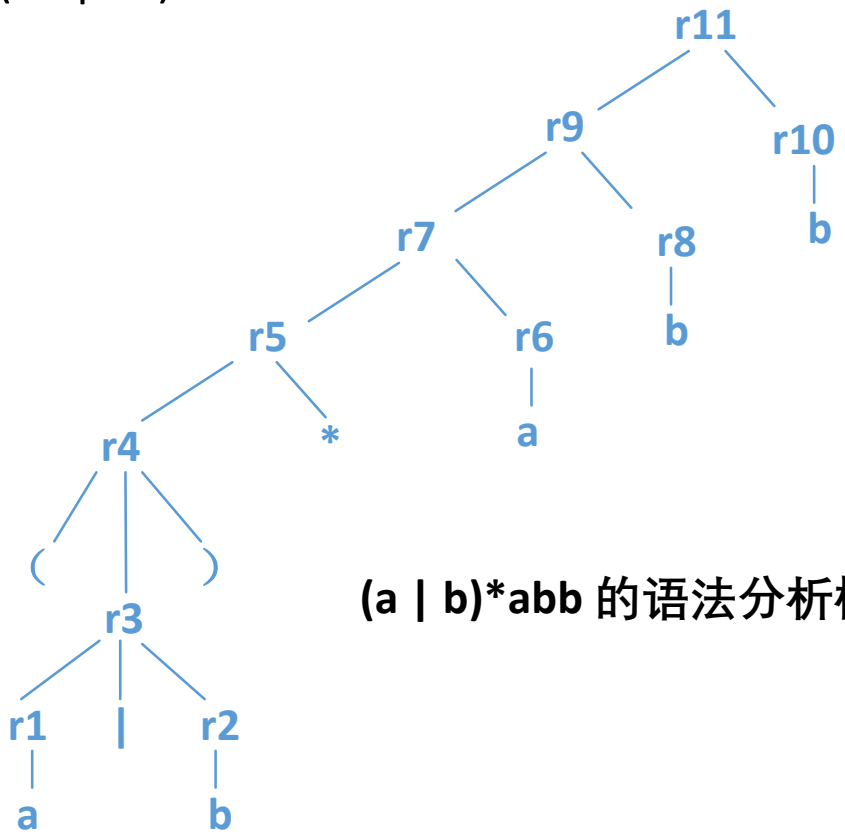

(a | b)*abb 的语法分析树

1.7 正规文法与有限自动机之间的关系

- 设$G=(V_N,V_T,P,S)$是正规文法，则存在一个有限自动机$\mathrm{M}=(Q,\ \Sigma,\ f,\ q_0,\ Z)$使得$L(G)=L(M)$

  右线性文法的自动机构造规则：
  - 令M中的Q=$V_N \cup \{T\}$，其中T是新增的接受状态；
  - 令$\Sigma=V_T$，$q_0=S$；
  - 若P中含有产生式$S\to\varepsilon$，则$Z=\{S,T\}$, 否则$Z=\{T\}$
  - 转换函数f构造如下
    - 对于P中每一条形如$A_1\to aA_2$的产生式，有$f(A_1,a)=A_2$
    - 对于P中每一条形如$A_1\to a$的产生式，有$f(A_1,a)=T$
    - 对于Σ上所有的a有$f(T,a)=\emptyset$，在接受状态下自动机没有动作

1.7 正规文法与有限自动机之间的关系

- 例：已知文法G=({S,A,B}, {a,b,c}, P, S)，其中P定义如下

1. S -> aS,
2. S -> aB,
3. B -> bB,
4. B -> bA,
5. A -> cA,
6. A -> c

试构造等价的自动机

解：按照构造规则，构造等价自动机为：

M=({S, A, B, T}, {a,b,c}, f, S, {T})

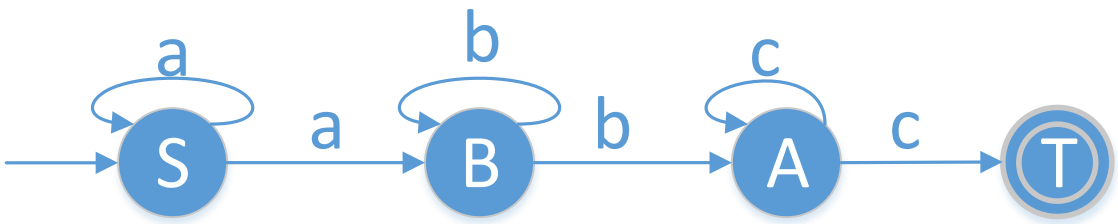

其中f定义如下：

1. f(S, a) = S
2. f(S, a) = B
3. f(B, b) = B
4. f(B, b) = A
5. f(A, c) = A
6. f(A, c) = T

1.7 正规文法与有限自动机之间的关系

- $G=(V_N,V_T,P,S)$，$\mathrm{M}=(Q，\ \Sigma，\ f，\ q_0，\ Z)$
- 左线性文法的自动机构造规则：
  - 令M中的$Q=V_N\cup\{q_0\}$，其中q_0是新增的初始状态；
  - 令$\Sigma=V_T$；
  - 若P中含有产生式$S\to\varepsilon$，则$Z=\{S,q_0\}$，否则$Z=\{S\}$
  - 转换函数f构造如下
    - 对于P中每一条形如$A_1\to A_2a$的产生式，$f(A_2,a)=A_1$
    - 对于P中每一条形如$A_1\to a$的产生式，$f(q_0,a)=A_1$

1.7 正规文法与有限自动机之间的关系

- 例：构造左线性文法G=({S,A,B}, {a,b}, P, S)的相应的自动机，其中P定义如下：
  1. S -> Sa | Aa | Bb
  2. A -> Ba | a
  3. B -> Ab | b

  解：按照构造规则，M = ({S, A, B, q_0}, {a, b}, f, q_0, {S})

  转换函数f定义为：

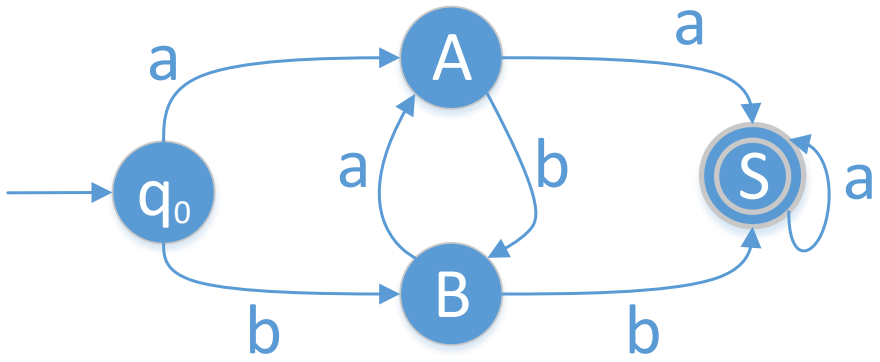

f(S, a) = S
f(A, a) = S
f(B, b) = S
f(B, a) = A

f(q_0, a) = A
f(A, b) = B
f(q_0, b) = B

第二节　词法分析程序的设计

2.1 预处理与超前搜索

- **预处理：**包括对空白符、跳格符、回车符和换行符等编辑性字符的处理，及删除注解，识别标号区、找出续行符连接成完整语句等
- **超前搜索：**当读到一个单词后，不能确定该单词的作用，要向前多读几个字符后才能确定；在读到一个单词之后，在缓冲区或扫描缓冲区上做标记，然后继续先前读，直到明确之后再退回标记处重新分析
  - 如算符的识别 C/C++，java的++，--，>=，!=，==等

2.2 扫描器的输出格式

- 词法分析程序通常又叫作扫描器
- 单词分类（Pascal语言为例）
  - **关键字：**具有特殊含义的标识符，起分隔语法成分的作用，如：program、var、procedure、begin、end
  - **标识符：**用于表示各种名字，如：变量名、数组名、函数名、过程名
  - **运算符**
    - 算术运算符+、－、*、/
    - 逻辑运算符：and、or、not
    - 关系运算符：>、>=、<、<=、=
  - **分界符：**‘,’、‘;’‘(’、‘)’、‘:’

2.2 扫描器的输出格式

- 扫描器的输出格式为二元式序列，每个单词对应一个二元式（类号，内码）
  - 类号用整数表示，区分单词的种类，方便程序处理
  - 每个关键字有一个类号，编译程序内部通常有关键字表，表中的编号可以用作类号，而内码可以省略
  - 对于标识符，内码用于区分标识符名，把符号表中地址作为内码
  - 常量，按不同类型分成相应类号，将常量表中的地址作为内码
  - 分界符，整型类号，内码可省略

2.3 扫描器的设计

- 用Lex建立词法分析器的步骤

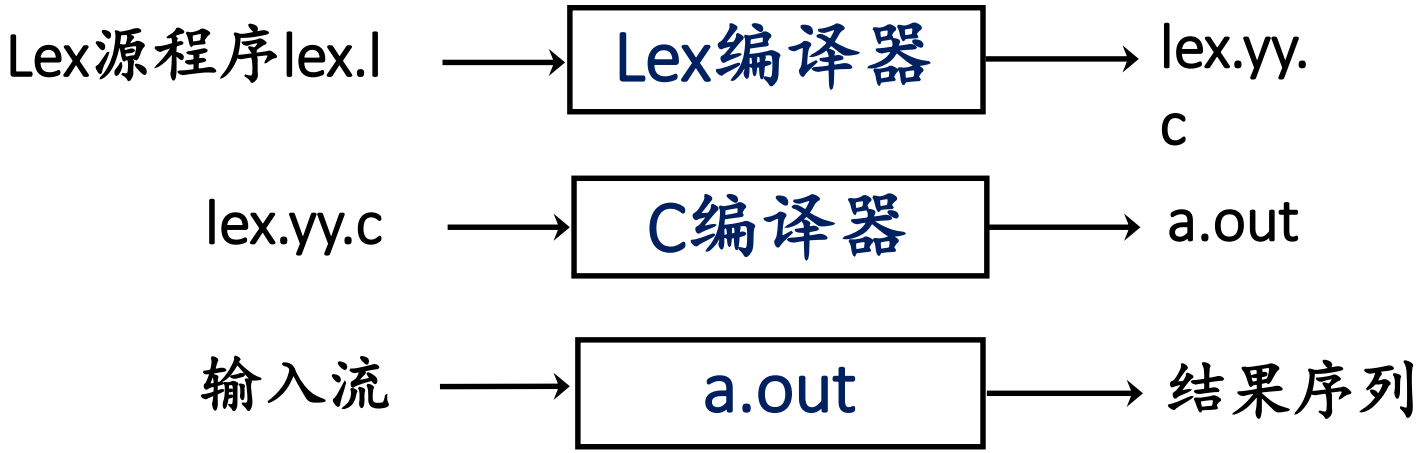

- 词法分析器仅返回记号名（代表词法单元的抽象名字）给语法分析器
- 记号的属性值通过共享整型变量yylval传递

2.3 扫描器的设计

- Lex程序包括三个部分

  声明
  %%
  翻译规则
  %%
  辅助过程

- Lex程序的翻译规则

模式	{动作}
p1	{动作1}
…	…
pn	{动作n}

- 每个模式是一个正规式
- 每个动作描述该模式匹配词法单元时，词法分析器应执行的程序段

2.3 扫描器的设计

- 例—声明部分

```
%{
/* 常量LT, LE, EQ, NE, GT, GE, WHILE, DO, ID, NUMBER,
   RELOP的定义,用C的#define方式来写*/
%}
/* 正规定义 */
delim          [  \t \n ]
ws             {delim}+
letter         [A –Za – z]
digit          [0–9]
id             {letter}({letter}|{digit})*
number         {digit}+(\ .{digit}+)?(E[+\–]?{digit}+)?
```

2.3 扫描器的设计

- 例—翻译规则部分

{ws}	{/* 没有动作，也不返回 */}
while	{return (WHILE);}
do	{return (DO);}
{id}	{yylval = install_id ( ); return (ID);}
{number}	{yylval = install_num( ); return (NUMBER);}
“ < ”	{yylval = LT; return (RELOP);}
“ <= ”	{yylval = LE; return (RELOP);}
“ = ”	{yylval = EQ; return (RELOP);}
“ <> ”	{yylval = NE; return (RELOP);}
“ > ”	{yylval = GT; return (RELOP);}
“ >= ”	{yylval = GE; return (RELOP);}

2.3 扫描器的设计

- 例—辅助过程部分

```
int installId ( ) {
        /* 把词法单元装入符号表并返回指针 */
}

int installNum ( ) {
        /* 类似上面的过程，但词法单元不是
           标识符而是数，并放入数表      */
}
```

- Lex最初的作者：Mike Lesk，Eric Schmidt (前谷歌CEO）

2.3 扫描器的设计

```
/* recognize tokens for the calculator and
print them out */
%{
   enum yytokentype {
      NUMBER = 258,
      ADD = 259,
      SUB = 260,
      MUL = 261,
      DIV = 262,
      ABS = 263,
      EOL = 264
  };

  int yylval;
%}

%%
```

```
"+"  { return ADD; }
"-"  { return SUB; }
"*"  { return MUL; }
"/"  { return DIV; }
"|"  { return ABS; }
[0-9]+  { yylval = atoi(yytext); return NUMBER; }
\n     { return EOL; }
[ \t]  { /* ignore whitespace */ }
.    { printf("Mystery character %c\n", *yytext); }
%%
int main(int argc, char **argv)
{
  int tok;
  while(tok = yylex()) {
      printf("%d", tok);
      if(tok == NUMBER) printf(" = %d\n", yylval);
      else printf("\n");
  }
}
```

小结

- 正规文法与有限自动机
  - 主要是DFA、NFA及正规式、正规文法
- 词法分析程序的设计
  - 了解实现词法分析程序的技术